

PROJEKT · ANALIZA MEDIJEV · STROJNO UČENJE

Medijska asimetrija

Analiza sentimenta slovenskega športnega poročanja na
RTV MMC (2023–2026)

Miha Perpar
Maj 2026

73k

VSEH ČLANKOV

10k

ANALIZIRANIH

12

ŠPORTOV

3

LETA PODATKOV

Ali novinarji reagirajo drugače na zmage kot na poraze?

- **Hipoteza:** slovensko poročanje o športu je asimetrično — odziv na zmage je intenzivnejši kot odziv na poraze
- RTV MMC kot javni medij z obveznostjo nevtralnosti je idealen predmet analize
- Podatki: YAML dump 73.461 člankov z naslovom, leadom, besedilom in datumom



Cilj: Izmeriti sentiment vsakega športnega članka in poiskati vzorce skozi čas — vrhe (zmage) in doline (porazi)

Pregledna stran — primerjava 12 športov

Sentiment v slovenskem športu

RTV MMC • 2023–2026 • Klikni šport za primerjavo

● Nogomet

615 člankov

Podrobno



● Rokomet

981 člankov

Podrobno



● Alpsko smučanje

1122 člankov


Podrobno



● Kolesarstvo

762 člankov

Podrobno



PRIMERJAVA


● Nogomet x

● Alpsko smučanje x

● Kolesarstvo x

Y: auto

Počni



- 12 športov urejenih po številu člankov
- LOWESS krivulja sentimenta za vsak šport
- Boxplot porazdelitve na desni
- Klik zgoraj → primerjalni panel (do 5 športov)
- Klik spodaj → detail stran

Detail stran — ekstremi in kontekst

KRIVULJA + SEZNAM EKSTREMOV



KLIKNJEN EKSTREM — WORD CLOUD + ČLANKI



Strojno učenje

Klasifikacija · Sentiment · Glajenje · Evalvacija

Sentence embeddingi + self-training

Korak 1: Embedding-based klasifikacija

- Model: `paraphrase-multilingual-MiniLM-L12-v2`
- Vsak članek → 384-dim. vektor (naslov + lead + ključne besede)
- Za vsak šport definiramo *sidro* — opis šport
- Dodelimo šport z najvišjo kosinusno podobnostjo
- Hitrost: ~5–15 s za 17.500 člankov na GPU

Korak 2: Self-training (iterativno)

- ~10–15% crossover med podobnimi športi (Rokomet ↔ Košarka)
- **1063 ročnih oznak** zbranih s terminal app
- Pseudo-labeli: top-150 zanesljivih primerov/šport
- Logistična regresija na embeddingih, 5-fold CV

Zakaj MiniLM? 10× hitrejši od večjih modelov, za klasifikacijo po temi zadostuje — semantiko razume, GPU ni potreben.

Primerjava treh modelov — Cohen's κ na 121 ročnih oznakah

MODEL	POZITIVNI	NEUTRALNI	NEGATIVNI	K
lxyuan/distilbert-base-multilingual	80%	-0%	20%	0.130
cardiffnlp/twitter-xlm-roberta-base	26%	69%	5%	0.143
cardiffnlp/xlm-roberta-base-sentiment-multilingual ✓	43%	52%	6%	0.305

lxyuan — praktično ne pozna nevtralnega razreda (0%). Neuporabno za naš task.

twitter-xlm — stara validacija (n=30) je dala $\kappa=0.35$, nova (n=121) samo 0.14. Precenjen.

xlm-roberta-multilingual — edini z realistično porazdelitvijo. Negative recall 35% — dejanska asimetrija je verjetno večja.

- Lead je pogosto kratek in ne zajame celotnega tona članka
- Jedro in zaključek nosita dodaten sentiment signal
- **Agregacija:** aritmetična sredina odstavkov → `sentiment_raw`
- Preskočimo odstavke z >25% besed v CAPS *KRKA – CIBONA*)
(rezultati: *92:97*)
- Preskočimo boilerplate: *Foto:, Preberite tudi:, ©*

+0.27

POVPREČNI
SENTIMENT

45%

POZITIVNIH
ČLANKOV

6%

NEGATIVNIH
ČLANKOV

Opomba: pozitivni naklon (+0.27) je konsistenten z asimetrično hipotezo — ob slabih rezultatih ton ni enako intenzivno negativen.

LOWESS z fiksnim oknom K=25 člankov

- LOWESS: neparametrično lokalno uteženo glajenje — vsaka točka krivulje temelji na K najbližjih člankih
- Zakaj K=25 (fiksno število, ne dnevi)?

S fiksnim oknom v dnevih bi Nogomet dobil 50+ člankov na točko, Biatlon pa 5 — **različna statistična zanesljivost**. K=25 zagotavlja enako zanesljivost ne glede na šport.

- Robovi krivulje se odrežejo (enostransko okno = nezanesljivo)
- Nevtralni članki izločeni pred računanjem (manj šuma)

ZAZNAVA EKSTREMOV

- `scipy.signal.find_peaks` s prominence pragom 8%
- Vrh velja samo če je **nad povprečjem** krivulje
- Dolina velja samo če je **pod povprečjem**

KLJUČNE BESEDE

- TF-IDF z background IDF: IDF fitamo na *vseh* člankih šport
- Penalizira stalne besede (npr. "Planica" pri vsakem skoku)
- Lematizacija z `lemmagen3` (slovenščina)

Generiranje word clouda — TF-IDF z background IDF

Problem z navadnim TF-IDF

- TF-IDF samo na kontekstnih člankih (± 14 dni) → besede z visokim TF so tiste, ki so pogoste v tem oknu
- A "Planica", "Prevc", vsakem smučarsko-skakalnem ekstremu — "Kobayashi" so pogoste niso specifične za ta dogodek pri
- Rezultat: word cloud ki ne pove nič novega

Rešitev: dvostopenjski TF-IDF

- **Fit** na vseh člankih šport → stalne besede dobijo nizek IDF (penalizacija)
- **Transform** samo kontekstnih člankov (± 14 dni) → ostanejo besede edinstvene za ta ekstrem
- Učinek: "Planica" dobi nizek score pri smučarskih skokih, izstopijo pa npr. "Granerud", "rekord", "padec"

OBDELAVA BESEDILA

- **Lematizacija** z `lemmagen3` (SL) *iger* → , *tekmovalcev* →
— *igra* *tekmovalec*
- Filtriramo: števila, besede ≤ 2 znaka, razširjen seznam slovenskih stopwords
- Top 20 besed po TF-IDF score

NORMALIZACIJA UTEŽI ZA VIZUALIZACIJO

- Surovi TF-IDF scores → normalizacija na **[0.25, 1.0]**
- Zagotavlja vsaj 4× vizualno razliko med prvo in zadnjo besedo
- Velikost besede v word cloudu = teža; barva = tip ekstrema (zelena/rdeča)

Rezultati in omejitve

Sentiment model ($\kappa = 0.305$)

- Zmerno strinjanje — sprejemljivo za domeno brez fine-tuninga
- Negative recall ~35%: model podcenjuje negativen sentiment
- 1063 ročnih oznak zbranih z namensko Flask + terminal app

Subjektivnost oznak: označevanje sentimenta je inherentno subjektivno — pri številnih člankih sam nisem bil prepričan v svojo oceno. Fine-tuning modela na takšnih oznakah bi model prilagodil *moji* subjektivni interpretaciji, ne dejanskemu sentimentu.

Zakaj je $\kappa=0.305$ vseeno dovolj: cilj je zaznati *trende* na stotinah člankov, ne klasificirati posamezni članek z visoko natančnostjo. Naključne napake se pri agregaciji povprečijo — signal ostane.

Opažena asimetrija

+0.27 POVPREČNI SENTIMENT
(LESTVICA -1 DO +1)

45 : 6 % POZITIVNIH VS NEGATIVNIH
ČLANKOV

Naslednji korak: korelacija sentimenta z izidi tekem (FIS / UEFA API) za formalen dokaz asimetrije.

Kar ni delovalo — modeli

✗ lxyuan/distilbert-multilingual

- Nevtralni razred praktično ne obstaja — model ga nikoli ne napove (~0%)
- Vse gre v pozitivno ali negativno → $\kappa=0.130$, neuporabno

✗ Utežena regresija odstavkov

- Ideja: lead/uvodni/vmesni/zaključni odstavek imajo različno težo
- Ridge regresija, 5-fold CV: $\kappa=0.317 \pm 0.221$ vs baseline 0.308
- Varianca ± 0.221 ogromna — le 24 vzorcev/fold, prenizko za stabilen fit

✗ Stara validacija twitter-xlm (n=30)

- Z $n=30$ ročnih oznak smo dobili $\kappa=0.35$ — zdelo se je dobro
- Z $n=121$ oznakami κ pade na 0.143 — bil je artefakt majhnega vzorca

✗ Self-training brez pseudo-labelov

- Prve oznake so prišle samo iz negotovih členkov → Rokomet, Odbojka sploh niso bili v training setu
- Model je napovedal samo Nogomet (10.749 člankov!) in Košarka
- Rešitev: pseudo-labeli top-150/šport iz originalne klasifikacije

Kar ni delovalo — implementacija

✗ LOWESS s fiksno frakcijo ($\text{frac}=0.08$)

- Za Nogomet (1885 člankov) okno vsebuje 150+ člankov → krivulja je ravna črta
- Za Biatlon (199 člankov) isto okno vsebuje le 16 → krivulja poskakuje
- Rešitev: $K=25$ fiksnih členkov, ne fiksna frakcija

✗ Zaznava ekstremov z `argrelextrema`

- Lokalni ekstremi brez minimalnega praga → šum zazna kot ekstreme
- Dip znotraj peaka zaznan kot dolina (lokalni minimum v naraščajoči krivulji)
- Rešitev: `find_peaks` s prominence pragom 8%, vrh le če nad povprečjem

✗ TF-IDF brez background IDF

- Navaden TF-IDF samo na kontekstnih člankih ± 14 dni
- Pri vsakem smučarsko-skakalnem ekstremu: "Planica", "Prevc", "Kobayashi" — prisotni v vsakem članku šport, niso specifični za ta ekstrem
- Rešitev: IDF fitamo na vseh člankih šport, ne samo kontekstu

✗ Sentiment samo na leadu (512 znakov)

- Lead je pogosto samo 1–2 stavka, prerezani na 70–80 besed
- Model XLM-RoBERTa podpira *tokenov* (~350 besed) — ne 512 znakov
- Rešitev: paragraph-level analiza, limit 2000 znakov/odstavkov

Povzetek

- Zgradili pipeline od surovih HTML-jev do interaktivne vizualizacije
- Klasifikacija 17.500 člankov v 12 športov z embeddingi + self-training LR
- Primerjali 3 modele, izbrali na podlagi κ in distribucije razredov
- LOWESS s fiksnim oknom $K=25$ za primerljive krivulje med šport
- Prominence-based zaznava ekstremov brez threshold tuninga

sentence-transformers

XLM-RoBERTa

LogisticRegression

TF-IDF

LOWESS

scipy.signal

D3.js

Flask

lemmagen3

Vir: **RTV MMC** · Apr 2023 – Mar 2026 · 10.055 analiziranih člankov

Diagnoza klasifikatorja — primerjava 7 pristopov

Ugotovljene težave

- **Pseudo-labeli iz cosine similarity škodijo:** 0.832 → 0.791 — napake iz koraka 01 se prenesejo kot resnica v LR trening
- **"Drugo" kot trening razred je problem:** precision 0.58 — kategorija je heterogena, model se je ne more naučiti
- **C=1 preveč regulariziran** za 384-dim embedding prostor; C=5 bistveno boljši
- **Keyword features so kritične:** brez njih accuracy pade z 0.83 na 0.67 (−16 pp)

Rešitev za Drugo: odstranimo ga iz trening razredov — namesto tega prag zaupanja 0.35. Če model ni zanesljiv, gre artikel v "Drugo" samodejno.

PRISTOP	CV ACC
LR C=1, ročne + pseudo	0.791
LR C=1, samo ročne	0.832
k-NN k=10, samo ročne	0.853
LR C=5, samo ročne	0.855
LR C=5, brez Drugo, prag 0.35	0.922

+9 pp samo z odstranitvijo pseudo-labelov, dvigom C in ločitvijo Drugo od trening razredov — brez novih oznak.

Iterativni self-training z LR pseudo-labeli

Pristop

- **Korak 1:** treniraj LR na 873 ročnih oznakah (CV: 0.915)
- **Korak 2:** predcira vse neoznačene članke s tem modelom
- **Pseudo-labeli:** top-50 na šport pri zaupanju $\geq 0.95 \rightarrow$ 550 novih labelov
- Ključna razlika od prej: *dobrega LR* (0.915), ne iz šumnega pseudo-labeli so iz *modela* cosine similarity
- **Retrenira** na 873 ročnih + 550 LR pseudo $\rightarrow$ CV: 0.952

Opomba: Športno plezanje (11 ročnih oznak) ni dobilo pseudo-labelov — model ni dosegel praga 0.95 za 50 člankov. Ta šport ostaja bolj negotov.

Napredek CV accuracy

IZHODIŠČE

LR C=1, ročne + cosine pseudo

0.832

PO DIAGNOZI

LR C=5, brez pseudo, prag Drugo

0.922

KONČNI MODEL

+ iterativni LR pseudo-labeli

0.952

+12 pp skupaj · Drugo: 2.574 $\rightarrow$ 1.399 člankov